

打标签方法论 · 测试文档

数据标注的核心难点，是把模糊的业务概念变成可重复的判断。模型可以承担候选生成、规则执行、难例筛选和质量检查；人的工作则集中在定义、校准、例外与独立验收这几件事情上。

不同领域不能按自动化率简单排队。判断评论态度、审阅合同特权、勾画病灶和记录机器人动作，所需知识、标签来源和错误代价都不同。医疗标注往往需要多读者独立读片，然后由第三方裁决分歧；法律取证强调的是可辩护性，也就是流程能不能向法院解释清楚。

一致性指标告诉我们标注者之间是否可比，但它不等于正确率。当一致性系数低于零点六六七时，通常说明定义本身需要重写，而不是继续加标注人力。

二、小团队的落地做法

先写一份两到四页的标注手册，把每个标签的定义、对象、正反例和困难例写清楚。然后留出独立的评测集，不要展示模型建议，也不要用它反复调提示词。生产批次可以让模型先预标注，再由人工随机盲审百分之二十，歧义、缺上下文和罕见类别单独加审。最后，一致性、正确性和分歧要分别报告，不要把有意义的不同意见裁决掉。